NAN_2

# HOMEPEDIA

T-DAT-902



# SOMMAIRE

DE LA PRÉSENTATION


01 *Contexte & Objectifs*

02 *Sources de données*

03 *Stack technique*

04 *Pipeline de traitement*

05 *Démonstration*

06 *Conclusion*

01

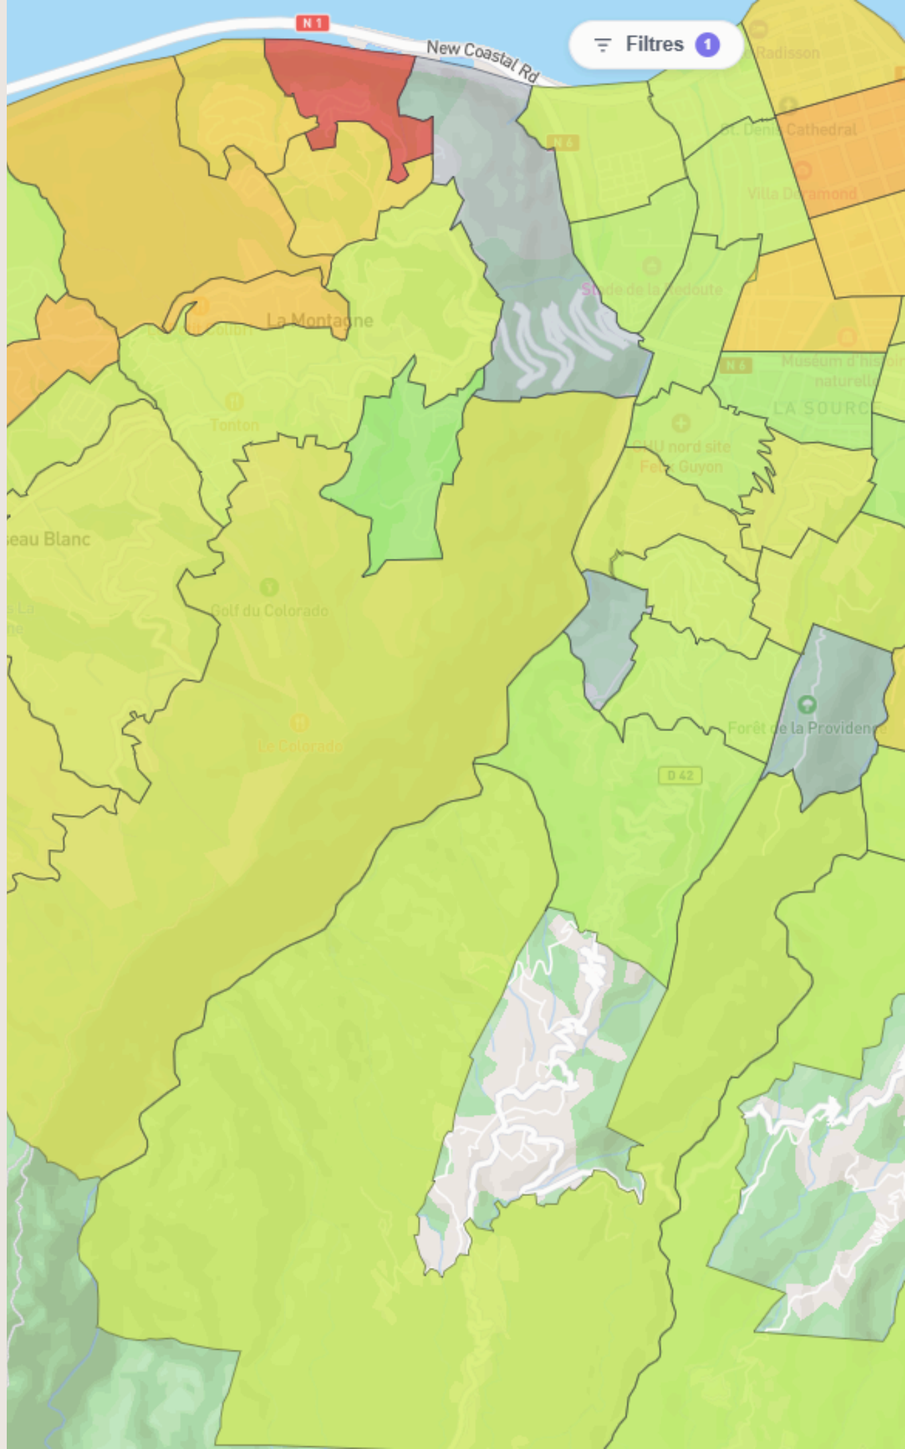
# CONTEXTE & OBJECTIFS

Le projet

- Plateforme d’analyser du marché immobilier français
- Données multi-niveaux : région, département, commune
- Métriques en dehors du prix : bien-être, éducation, énergie, environement
- Carte interactive, tableaux, analyse textuelle

Attendus

- App interactive
- Cartographie
- Analyse textuelles & avis
- Schéma BDD + néttoyage des données
- Spark



02

# SOURCES DE DONNEES

## DVF - DEMANDES DE VALEURS FONCTIÈRES

Source : data.gouv.fr - Données de transactions immobilières (ventes)
Fréquence : semestriel

## ANIL - CARTE DES LOYERS 2025

Source : data.gouv.fr - Indicateurs de loyers d'annonce par commune
Fréquence : annuel
Loyers médians, fourchettes de prix par type de logement

## ENVIRONNEMENT

Source : data.gouv.fr - Indicateurs de loyers d'annonce par commune
Fréquence : annuel
Loyers médians, fourchettes de prix par type de logement

## CARTOGRAPHIE

Découpage administratif /

## SOCIO-ECONOMIQUES

Source : data.gouv.fr - Indicateurs de loyers d'annonce par commune
Fréquence : annuel
Loyers médians, fourchettes de prix par type de logement

## INFRASTRUCTURE

Source : data.gouv.fr - Indicateurs de loyers d'annonce par commune
Fréquence : annuel
Loyers médians, fourchettes de prix par type de logement

02

# SCRAPER

## INDICATEURS SOCIO-ECONOMIQUES

Recensement de la population (INSEE)

Délinquance enregistrée

Revenus et pauvreté (INSEE 2021)

## AVIS & OPINIOS

bien-dans-ma-ville.fr

ADEME - Datasets

03

# STACK TECHNIQUE





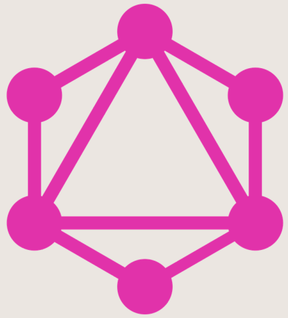














05

# PIPELINE DE TRAITEMENT

## INGESTION

Scripts Python

Téléchargement automatisé

## TRAITEMENT

PySpark

Nettoyage & agégation

## STOCKAGE

PostGIS + MongoDB

## VISUALISATION

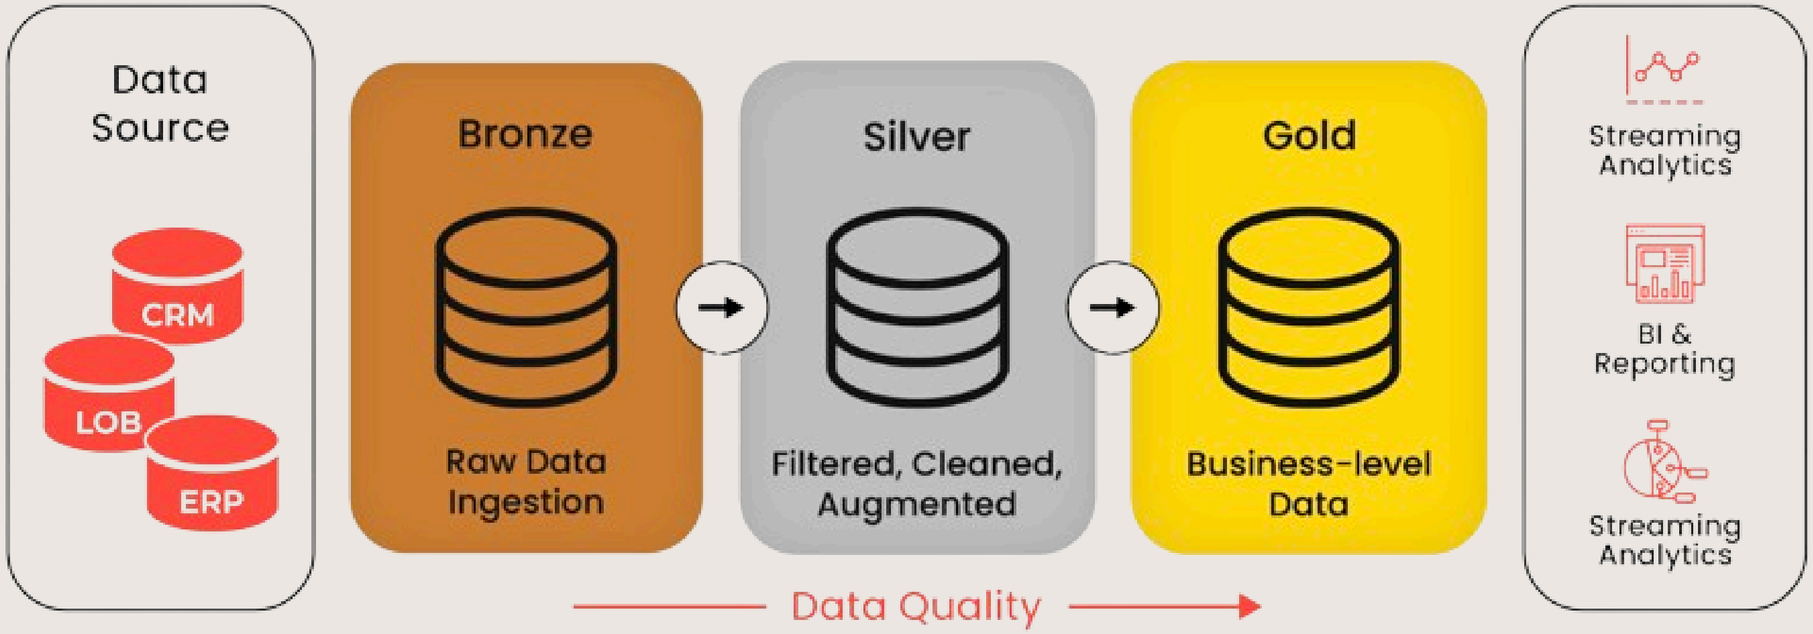
Angular

Cartes & Graphiques

Orchestré par Airflow

05

# WORKFLOW SPARK



02

# NLP

## TRAITEMENT DES AVIS

Analyse des avis avec
**bert-base-multilingual-uncased-sentiment**

Notation de 0 à 5



# DEMO

02

# DIFFICULTES

Sourcage des données

Données pas toujours à jour

Volume de données

Performances matériel

02

# AMELIORATIONS

Affichage de source de données différentes

Amélioration des performances front

Meilleur gestion du schedule des DAG Airflow

MERCI

05

# SCHEMA BDD

